

第1章 绪论

1.1 课题背景概述

随着移动互联网和物联网设备的快速发展，大量数据分散存储在用户终端设备中。传统的集中式机器学习需要将数据集中上传到服务器进行统一训练，但这种方式在现实应用中面临严重的隐私泄露风险，同时也可能违反数据保护相关法规。为解决这一问题，Google 于 2017 年提出了联邦学习（Federated Learning）框架[1]，该框架允许各客户端在本地利用自身数据训练模型，仅将模型参数上传至服务器进行聚合，从而在不直接共享原始数据的情况下实现协同学习。

然而在实际应用场景中，不同客户端的数据往往具有显著差异，这种现象被称为数据异构或 Non-IID（Non-Independent and Identically Distributed）问题[2]。例如，不同用户设备产生的数据类别比例不同、采集环境不同或存在明显的分布偏移，这会导致客户端模型在本地训练时优化方向不一致，从而产生所谓的“客户端漂移（Client Drift）”问题，使得全局模型的收敛速度和泛化能力明显下降。针对这一问题，国内外学者提出了多种改进方法。

1.2 现有解决方法

目前已有研究主要集中在以下几个方向：第一类是优化算法改进方法，例如 FedProx[3]、SCAFFOLD[4]、FedNova[5] 等算法通过引入额外的正则化项或梯度校正机制来减少局部模型更新偏差，从而缓解数据异构带来的影响。第二类是个性化联邦学习方法，例如 FedSPU[6]、Look Back for More[7] 等方法通过在模型中引入个性化参数或利用历史更新信息，使客户端模型能够更好地适应本地数据分布。第三类方法是结构或表示共享方法，例如在联邦图学习领域中提出的虚拟节点（Virtual Nodes）[8]或原型共享（Prototype Sharing）[9]机制，通过共享部分结构化信息实现跨客户端表示对齐。第四类是近年来提出的特征蒸馏与信息分解方法，通过共享不具备隐私风险的敏感特征来缓解数据异构问题，例如，NeurIPS 2023 提出的 FedFed 方法通过数据蒸馏机制将原始数据划分为性能敏感特征和性能鲁棒特征，其中敏感