

第2章 相关理论与方法基础

2.1 联邦学习

联邦学习是一种面向多客户端数据协同建模的分布式机器学习范式，其核心思想是在不直接汇聚各客户端原始数据的前提下，由服务器协调多个客户端共同训练全局模型。典型流程包括：服务器初始化全局模型并下发给被选中的客户端；客户端基于本地私有数据进行若干轮本地训练；客户端将模型参数或模型更新上传至服务器；服务器根据各客户端样本数量或更新权重进行聚合，得到新的全局模型；上述过程循环执行，直至模型收敛或达到预设通信轮数。该机制能够降低原始数据集中存储带来的隐私风险和通信成本，但也面临数据异构、设备异构、通信不稳定等问题，其中 Non-IID 数据分布是影响联邦模型性能的重要因素之一[11]。

2.2 FedAvg

FedAvg 是联邦学习中最基础、应用最广泛的优化算法之一。该算法在每一轮通信中随机选取部分客户端参与训练，各客户端从服务器接收当前全局模型后，在本地数据上执行多步随机梯度下降，然后将训练后的模型参数上传至服务器。服务器按照客户端本地样本数量对模型参数进行加权平均，形成下一轮全局模型。与每一步梯度都进行通信的 FedSGD 相比，FedAvg 通过增加客户端本地训练步数显著减少通信频率，因此具有较高的通信效率[12]。但是，在客户端数据分布高度异构时，本地模型更新方向可能存在明显偏移，简单加权平均容易导致全局模型收敛变慢或精度下降。

2.3 FedProx

FedProx 可以看作是对 FedAvg 的一种稳健化改进，主要用于缓解联邦学习中的系统异构和统计异构问题。FedProx 在客户端本地目标函数中加入近端正则项，使本地模型在训练过程中不要过度偏离当前全局模型。其本地优化目标通常可表示为原始经验风险项加上 $\mu/2 ||w - w_t||^2$ ，其中 w_t 为当前轮次下发的全局模