

型参数， μ 控制近端约束强度。该设计使客户端即使在数据分布差异较大或本地训练步数不一致的情况下，也能保持相对稳定的更新方向，从而提高异构场景下的训练稳定性[13]。因此，FedProx 很适合作为本文插件化适配实验中的第二个基线算法。

2.4 FedNova

FedNova 主要针对异构联邦优化中的“目标不一致”问题。FedAvg 在不同客户端本地训练步数不一致时，直接对本地模型结果进行加权平均，可能导致全局模型实际优化的目标函数与原始联邦优化目标不一致。FedNova 通过对客户端本地更新进行归一化处理，使服务器聚合时考虑不同客户端实际执行的本地更新量，从而减轻由本地步数差异带来的聚合偏差[14]。与 FedProx 通过修改本地目标函数增强稳定性不同，FedNova 更关注服务器端聚合更新的规范化问题，体现了从“聚合规则”角度处理异构性的思路。

2.4 SCAFFOLD

SCAFFOLD 针对 Non-IID 数据下客户端更新方向偏移的问题，引入控制变量对本地更新进行校正。其基本思想是分别维护服务器端和客户端的控制变量，用于估计并修正本地梯度与全局梯度之间的偏差，从而降低 client drift 对全局收敛的影响。与 FedAvg 直接聚合本地模型不同，SCAFFOLD 通过控制变量显式约束客户端更新方向，使其在理论上能够更好地应对数据异构和客户端采样带来的不稳定性[15]。该类方法说明，Non-IID 问题不仅可以从数据共享或特征共享角度解决，也可以从优化校正角度进行处理。

2.5 数据蒸馏与特征分离思想

传统意义上的数据蒸馏通常指将大规模训练数据压缩为少量具有代表性的合成样本，使模型在这些小规模蒸馏数据上训练后仍能接近原始数据集训练效果[16]。但本文所讨论的 FedFed 图像插件中的“蒸馏”更接近 FedFed 论文中的特征蒸馏与数据特征分离思想，并不是常规的教师-学生知识蒸馏。FedFed 借助生成器 $q(x)$ 将原始输入样本 x 分解为性能鲁棒特征 $x_r = q(x)$ 和性能敏感特征 $x_s = x - q(x)$ ，其中性能敏感特征包含对分类性能更关键的信息，可在服务器端共享以缓解客户端间的