

数据异构，而性能鲁棒特征则保留在本地，以降低直接共享原始数据带来的隐私风险[18]。在实现上，本文主线采用 Beta-VAE 类生成器结构，其理论基础与变分自编码器中的潜变量建模和重参数化训练方法有关[17]。

2.7 FedFed

FedFed 是本插件项目所参考的方法，它的核心目标是在隐私保护和模型性能提升之间取得折中：不直接共享客户端原始图像，而是共享从原始图像中提取出的性能敏感特征。其整体流程可以分为两个阶段。第一阶段为特征蒸馏阶段，客户端训练生成器 $q(x)$ 和蒸馏分类器，使 $x_s = x - q(x)$ 具有较强的类别判别能力，同时通过重构损失、KL 损失和范数约束限制特征分离过程，避免敏感特征退化为原始图像复制。客户端按类别筛选并上传部分性能敏感特征，服务器将其维护为共享特征池。第二阶段为正式联邦训练阶段，服务器向客户端下发全局模型和共享敏感特征，客户端同时利用本地数据和共享特征参与训练，再将模型更新上传给服务器聚合。FedFed 方法证明了共享性能敏感特征能够缓解数据异构对联邦训练的影响[18]。本文基于其官方代码结构和算法流程进行工程化重构，将生成器训练、敏感特征上传、共享特征池维护和共享特征辅助训练封装为 FedFed 插件，从而实现 FedFed 机制在联邦学习框架中的插件化接入[19]。




图 1 FedFed 方法特征分离机制示意图