

4.2.2 特征蒸馏网络结构设计

特征蒸馏网络由生成器和分类器组成。生成器负责从原始图像中生成性能鲁棒特征，蒸馏分类器负责约束性能敏感特征的类别判别能力。

本文采用 **Beta-VAE** 风格生成器。其结构包括编码器、潜变量层和解码器。编码器将输入图像压缩为潜在表示，潜变量层通过均值和方差建模隐空间分布，解码器将潜变量恢复到图像空间。生成器输出记为性能鲁棒特征，原始图像与生成器输出的差值记为性能敏感特征。

Beta-VAE 的作用不是单纯重构图像，而是在有限潜变量容量下保留图像主体信息。通过这种约束，生成器倾向于保留对分类贡献较弱的鲁棒部分，而差值部分保留更多与标签相关的判别信息。

分类器接收性能敏感特征并预测其标签。若敏感特征能够被正确分类，说明其中包含对模型性能有贡献的信息。因此，生成器和蒸馏分类器共同实现特征分离：重构约束保证鲁棒特征有效，分类约束保证敏感特征可用，潜变量约束保证生成过程稳定。

4.2.3 特征蒸馏目标设计

特征蒸馏阶段的目标是学习一个生成器，使其能够从原始图像中分离出性能敏感特征；同时训练蒸馏分类器，使该敏感特征保留类别判别信息。本文采用的蒸馏目标函数为：

$$L_{distill} = \lambda_{fd} CE(C(x_s), y) + \lambda_{re}(t) \|G(x) - x\|_2^2 + \lambda_x CE(C(x), y) + \beta L_{kl}$$

其中， x 表示客户端本地输入图像， y 表示对应类别标签， $G(\cdot)$ 表示生成器， $C(\cdot)$ 表示分类器。生成器输出 $G(x)$ 被视为性能鲁棒特征，性能敏感特征定义为：

$$x_s = x - G(x)$$

第一项为性能敏感特征分类损失：

$$\mathcal{L}_{fd} = CE(C(x_s), y)$$

该项要求蒸馏分类器能够根据性能敏感特征预测真实标签。它直接约束 x_s 保留与分类任务相关的信息，是特征蒸馏阶段的核心监督信号。

第二项为图像重构损失：

$$\mathcal{L}_{re} = \|G(x) - x\|_2^2$$