

分布。第二，使客户端在正式训练阶段可以按类别采样共享特征，从而获得更均衡的类别信息。

为控制存储开销，服务器对共享池设置容量限制。容量控制同样包括两个层面：全局容量上限和单类别容量上限。当共享池总量或某一类别的特征数量超过限制时，服务器会移除较早加入的特征，只保留当前容量范围内的共享样本。

4.4.3 正式训练阶段使用方式

共享样本池构建完成后，插件在正式联邦训练阶段用于增强客户端本地训练。该阶段仍以 FedAvg 为主训练框架，服务器每轮选择部分客户端，下发全局模型参数，同时下发共享样本池中的性能敏感特征及其标签。客户端使用本地数据和共享样本共同训练主分类模型。

设主分类模型为 $F(\cdot)$ ，客户端本地样本为 (x, y) ，服务器下发的共享性能敏感特征及其标签为 $(\tilde{x}_s, \tilde{y})$ 。正式训练阶段的本地目标函数为：

$$\mathcal{L}_{train} = \frac{1}{3}CE(F(x), y) + \frac{2}{3}CE(F(\tilde{x}_s), \tilde{y})$$

其中，第一项为本地数据分类损失，第二项为共享敏感特征分类损失。共享样本不替代本地数据，而是作为辅助输入提供跨客户端类别判别信息。该设计能够缓解客户端本地数据类别分布偏斜，使本地模型更新方向更接近全局任务目标。

该阶段不改变 FedAvg 的服务器聚合规则。客户端训练结束后仍上传主分类模型参数和样本数量，服务器仍按照样本数量进行加权平均。插件的作用集中在本地训练目标中，即通过共享性能敏感特征提高客户端训练数据的有效类别覆盖。

4.5 本章小结

本章介绍了 FedFed 特征蒸馏插件的设计与实现。该插件基于图像空间特征分离思想，将客户端本地图像划分为性能鲁棒特征和性能敏感特征，并通过生成器、分类器和共享样本池实现跨客户端的信息共享。系统采用两阶段训练机制，先进行特征蒸馏和共享样本池构建，再在正式 FedAvg 训练中利用共享特征辅助本地模型训练。该插件在保持 FedAvg 主流程不变的前提下，为异构联邦学习提供了额外的特征共享能力。