

表 6-1 特征蒸馏机制诊断结果

代理任务	输入含义	BestAcc	FinalAcc	BestEpoch
$x \rightarrow x$	原始图像分类	69.55%	69.55%	10
$x_s \rightarrow x_s$	敏感特征分类	74.00%	74.00%	10
$x_r \rightarrow x_r$	鲁棒特征分类	54.23%	53.53%	7
$x_s \rightarrow x$	敏感特征到原图迁移	14.29%	14.29%	10
$x+x_s \rightarrow x$	原图与敏感特征联合训练	73.58%	71.29%	8
$x+x_p \rightarrow x$	原图与带噪敏感特征联合训练	71.28%	71.22%	7

表中，BestAcc 表示代理分类器训练过程中的最高测试准确率，FinalAcc 表示训练结束时的测试准确率，BestEpoch 表示取得最高准确率的训练轮次。 x_s 表示性能敏感特征， x_r 表示性能鲁棒特征， x_p 表示加入扰动后的性能敏感特征。

由表 6-1 可知， $x_s \rightarrow x_s$ 的最高准确率达到 74.00%，高于原始图像代理任务 $x \rightarrow x$ 的 69.55%，说明性能敏感特征中保留了较强的分类判别信息。相比之下， $x_r \rightarrow x_r$ 的最高准确率为 54.23%，明显低于 $x_s \rightarrow x_s$ ，说明性能鲁棒特征中的分类信息相对较弱。该结果符合 FedFed 的特征蒸馏目标：敏感特征主要承载与分类任务相关的信息，鲁棒特征更多保留非关键的隐私信息。

同时， $x+x_s \rightarrow x$ 的最高准确率达到 73.58%，高于单独使用原始图像的 $x \rightarrow x$ ，说明敏感特征可以作为有效的辅助训练信息。加入扰动后的 $x+x_p \rightarrow x$ 仍取得 71.28% 的最高准确率，表明扰动后的敏感特征仍然保留任务可用性。结合前文隐私验证结果可知，带噪敏感特征在保持分类辅助作用的同时，可以降低直接反演原始图像的风险。