




图 6-1 不同特征输入形式下的分类诊断结果

图 6-1 对比了原始图像、敏感特征、鲁棒特征和带噪敏感特征的分类代理性能。结果显示，敏感特征具有较强分类能力，鲁棒特征分类性较弱，说明 FedFed 插件的特征蒸馏过程能够将更多分类相关信息集中到可共享特征中。

6.2 隐私验证

FedFed 插件通过共享性能敏感特征缓解客户端数据异构问题，但共享特征本身仍可能带来隐私泄露风险。为验证本文插件在共享特征过程中的隐私表现，本节从敏感特征范数、模型反演攻击和成员推断攻击三个角度进行实验分析。

6.2.1 隐私验证思路

本文中特征蒸馏阶段将原始图像 x 分解为性能鲁棒特征 x_r 和性能敏感特征 x_s ，其中：

$$x_s = x - x_r$$

性能敏感特征 x_s 包含较强的分类判别信息，因此可以用于辅助联邦训练。但如果直接共享 x_s ，攻击者可能通过反演攻击恢复原始图像，或通过成员推断攻击判断某个样本是否参与过训练。

因此，本文在共享前对 x_s 引入 L2 范数剪裁和高斯噪声扰动。具体做法为：首