

先对每个样本的敏感特征进行 L2 范数剪裁，将其范数限制在阈值 C 内；随后参考 FedFed 原论文中的噪声注入方式，对剪裁后的敏感特征加入高斯噪声，得到带噪敏感特征 x_p 。

本文使用 $x+x_p \rightarrow x$ 的分类代理任务评估带噪敏感特征的可用性。这里的 $x+x_p$ 并不是指将原始图像和带噪敏感特征逐元素相加，而是指在分类器训练时同时使用原始图像 x 和带噪敏感特征 x_p 作为训练样本，并在测试时使用原始图像 x 进行分类评估。若该分类器仍能取得较高准确率，说明 x_p 中保留了对分类任务有用的信息，能够作为共享辅助特征参与训练。

6.2.2 敏感特征剪裁与噪声设置

在确定剪裁与噪声参数前，本文首先统计蒸馏阶段得到的敏感特征 x_s 的 L2 范数分布。该实验的目的是观察 x_s 的实际数值规模，避免在不了解特征范数的情况下直接设置剪裁阈值或噪声强度。若剪裁阈值过小，会破坏大量有效特征；若阈值过大，则少量异常大范数样本可能削弱固定噪声的扰动效果。

图 6-2 展示了不同配置下敏感特征 x_s 的 L2 范数统计结果。




图 6-2 敏感特征 L2 范数统计对比

实验结果显示，在无剪裁无噪声配置下，测试集 x_s 的平均范数约为 8.30，p95 为 11.61，p99 为 13.29，最大值达到 23.23。这说明大部分敏感特征集中在 10 左