

右,但仍存在少量明显偏大的样本。因此,本文选择 $C=10$ 作为剪裁阈值。该阈值能够覆盖主要样本分布,同时限制高范数异常样本。

采用 $C=10$ 后,测试集 x_s 的 $p95$ 、 $p99$ 和最大范数均被限制在 10 附近,说明剪裁机制按预期生效。与此同时,最佳配置下 x_p 的平均范数约为 11.68, $p95$ 约为 13.09,表明噪声扰动后特征规模仍处于可控范围内,没有出现明显数值失控。

在噪声强度选择上,本文对多组高斯噪声配置进行了对比。实验发现, $C=10$ 、Gaussian(0.15, 0.20) 在分类代理准确率和反演风险之间取得较好折中:相较无剪裁无噪声配置,分类代理准确率仅下降约 1.22 个百分点,同时反演 PSNR 从 18.87 降至 16.58。因此,本文将该组参数作为后续分析的最佳配置。

最佳配置为:

$$C = 10, \quad \sigma_1 = 0.15, \quad \sigma_2 = 0.20$$

其中, C 为敏感特征 L2 范数剪裁阈值, σ_1 和 σ_2 为两路高斯噪声标准差。本文采用两路噪声设置,主要参考 FedFed 原论文中对敏感特征加入两种强度扰动的思想。其基本考虑是:较弱噪声用于保留敏感特征中的主要判别信息,使带噪特征仍能辅助分类训练;较强噪声用于进一步增强共享阶段的扰动强度,降低敏感特征被直接恢复的风险。通过设置两种噪声强度,系统能够在特征可用性和隐私扰动之间进行折中,而不是只依赖单一噪声强度。

在本文实验中, σ_1 主要用于构造隐私验证中的带噪敏感特征, σ_2 用于对应共享阶段更强扰动设置,二者共同构成本文对 FedFed 噪声扰动思想的实现。

6.2.3 模型反演攻击验证

模型反演攻击用于评估攻击者能否从共享特征中恢复原始图像。本文训练一个反演网络,以带噪敏感特征 x_p 为输入,以原始图像 x 为重建目标,并使用 MSE、L1 误差和 PSNR 衡量重建质量。

其中, MSE 表示重建图像与原始图像之间的均方误差,数值越大表示重建误差越大; L1 误差表示像素级绝对误差的平均值,数值越大表示重建结果与原图差异越大; PSNR 表示峰值信噪比,数值越高表示重建图像越接近原图,数值越低表示反演恢复越困难。分类代理准确率 $x+x_p \rightarrow x$ Acc 用于衡量带噪敏感特征对分类任务的