

可用性，数值越高表示特征仍保留较强任务信息。

表 6-2 模型反演攻击结果

配置	C	噪声设置	$x+x_p \rightarrow x$ Acc	MSE	L1	PSNR
无剪裁无噪声	-	None	63.33%	0.01296	0.08661	18.87
最佳配置	10	Gaussian(0.15,0.20)	62.10%	0.02196	0.11201	16.58

由表 6-2 可知，最佳配置下分类代理准确率由 63.33% 下降至 62.10%，仅下降约 1.22 个百分点，说明剪裁与噪声对特征可用性的影响较小。同时，模型反演 MSE 由 0.01296 增大至 0.02196，L1 误差由 0.08661 增大至 0.11201，PSNR 由 18.87 降低至 16.58。三项反演指标均表明，攻击者从带噪敏感特征中恢复原始图像的难度明显增加。

为进一步直观观察反演攻击效果，本文分别给出无剪裁无噪声配置和最佳配置下的模型反演可视化结果，如图 6-3 和图 6-4 所示。




图 6-3 无剪裁无噪声配置下的模型反演结果




图 6-4 最佳配置下的模型反演结果

图中每组样本依次展示原始图像、共享特征、反演重建图像和重建误差。无剪