

裁无噪声配置下，反演网络能够从共享敏感特征中恢复出较明显的图像结构和颜色分布；而在最佳配置下，反演重建图像更加模糊，局部细节和类别相关视觉结构明显减弱，重建误差更加突出。该现象与表 6-2 中的定量结果一致，说明剪裁与噪声扰动降低了共享敏感特征的可反演性。

6.2.4 成员推断攻击验证

成员推断攻击用于判断某个样本是否参与过目标模型训练。本文采用基于影子模型的成员推断攻击，即 Shadow Model-based Membership Inference Attack。该攻击假设攻击者无法直接获得目标训练集，但可以获得与目标任务分布相似的辅助数据，并能够查询目标模型输出。在联邦学习场景中，攻击者可以被建模为潜在恶意客户端，其能够获得服务器下发的全局模型，并利用自身持有的同分布数据训练影子模型。

具体流程如下。攻击者首先将辅助数据划分为 shadow train 和 shadow test，其中 shadow train 用于训练影子模型，shadow test 不参与影子模型训练。由于影子模型由攻击者自行训练，因此 shadow train 样本被标记为 member，shadow test 样本被标记为 non-member。随后，攻击者使用与目标模型相同的输入形式训练多个影子模型，并将样本输入影子模型，提取模型输出中的 top-k 概率、置信度、预测间隔、熵、真实类别概率和交叉熵损失等统计特征。最后，攻击者使用这些统计特征训练二分类攻击模型，并将该攻击模型迁移到目标模型上进行成员推断。

为避免攻击模型过弱导致低估成员推断风险，本文进一步增强 Shadow MIA 设置，包括增加 shadow model 数量、增加影子模型训练轮数，并扩大成员推断评估样本数量。增强后的实验设置和结果如表 6-3 所示。

表 6-3 增强 Shadow MIA 设置下的成员推断攻击结果

配置	Shadow	Shadow	MIA	MIA	Attack	Member	Member
	Models	Epochs	Samples	AUC	Acc	Recall	Precision
无剪裁无噪声	5	20	1500	0.702	63.43%	96.80%	58.06%
最佳配置	5	20	1500	0.769	69.17%	97.73%	62.20%