

其中，Shadow Models 表示训练的影子模型数量；Shadow Epochs 表示每个影子模型的训练轮数；MIA Samples 表示用于目标模型成员推断评估的成员样本和非成员样本数量。MIA AUC 衡量攻击模型区分成员样本和非成员样本的整体能力，越接近 0.5 表示越接近随机猜测，越接近 1 表示攻击能力越强。Attack Acc 表示攻击模型最终二分类准确率；Member Recall 表示真实成员样本中被识别为成员的比例；Member Precision 表示被攻击模型判断为成员的样本中真实成员所占比例。

从增强攻击结果看，无剪裁无噪声配置下 MIA AUC 为 0.702，说明在较强影子模型攻击设置下，攻击者已经能够获得一定成员区分能力。最佳配置下 MIA AUC 进一步升至 0.769，Attack Acc 由 63.43% 提高至 69.17%。该结果表明，剪裁与噪声扰动虽然降低了模型反演风险，但并未稳定降低成员推断风险。

造成这一现象的原因在于，模型反演攻击和成员推断攻击关注的泄露形式不同。模型反演攻击关注能否从共享特征恢复原始图像，而成员推断攻击关注模型对成员样本和非成员样本的输出差异。加入固定噪声后，带噪敏感特征的图像细节被破坏，因此反演难度增加；但固定带噪特征也可能使模型对训练样本产生更明显的输出记忆，从而增大成员样本与非成员样本在置信度、熵和损失等统计特征上的差异。因此，本文认为该剪裁与噪声机制主要降低共享特征的反演风险，而不能视为完整的成员隐私保护方法。

6.2.5 隐私验证结果分析

图 6-5 汇总展示了不同配置下的分类代理准确率、MIA AUC 和模型反演 PSNR。




图 6-5 不同配置下的性能与隐私指标对比